דו"ח מסכם סוף סמסטר ב'

מגישות:

סהר בנישתי
נאות דוכן
הודיה ארביב

תוכן עניינים

רקע..... 2

שאלת המחקר 2

מטרת הפרויקט 2

מדד הצלחה 2

סקירת ספרות 3

הידע הקיים והפער המחקרי.....3

הנתונים הגולמיים..... 3

ניקוי ועיבוד הנתונים 4

קידוד ונרמול למשתנים 4

סטטיסטיקה תיאורית..... 5

סטטיסטיקה תיאורית- קשר בין עומס ליום בשבוע..... 5

סטטיסטיקה תיאורית- קשר בין סוג המשימה לזמן הטיפול..... 6

סטטיסטיקה תיאורית- קשר בין משתנים שונים לרמת העומס..... 7

גיבוש התכונות שיכללו ברשומת הקלט.....8

השלבים בתהליך למידת מכונה.....10

הגדרת משתנה מטרה.....10

אלגוריתמים מבוססי עצים.....10

מודלים לחיזוי נפח פניות- סדרות זמן.....10

ניתוח הגרפים.....11

ניתוח הבדיקות שאחרי הרצת המודלים.....13

מסקנות ותובנות.....14

שאלות ותשובות.....14

רקע

מוקד השירות העירוני מהווה נקודת מגע מרכזית בין התושבים לרשות המקומית. המוקד מרכז פניות מערוצים שונים כגון טלפון, וואטסאפ וטפסים מקוונים.
ביישוב אבן יהודה קיים עומס פניות משמעותי, כאשר המוקד מאויש על ידי מוקדנית אחת בלבד במשמרת. מצב זה יוצר אתגר בניהול הפניות, בתיעדוף ובמעקב אחרי הטיפול בהן. לכן קיים צורך בניתוח נתוני הפניות לצורך זיהוי דפוסים, שיפור תהליכי עבודה ושיפור חוויית השירות לתושב.

שאלת המחקר

כיצד ניתן לייעל את תכנון המשאבים והשירות לתושב באמצעות מודלים לחיזוי נפח הפניות, זיהוי חריגות מזמני התקן, ואפיון גורמי העיכוב המרכזיים בטיפול בפניות הציבור?

מטרת הפרויקט

מטרת הפרויקט היא לשלב בין שני כיווני ניתוח מרכזיים:

1. הפקת תובנות תפעוליות לשיפור השירות העירוני-
באמצעות ניתוח נתוני פניות התושבים זוהו דפוסים בעומס הפניות, זמני הטיפול וסוגי הפניות המרכזיים. מטרת הניתוח היא לאפשר לרשות המקומית לקבל החלטות מבוססות נתונים בנוגע להקצאת משאבים, תיעדוף משימות ושיפור תהליכי עבודה.

2. פיתוח יכולת חיזוי של עומסי הפניות למוקד העירוני-
פותחו מודלים לחיזוי נפח הפניות וזמני הטיפול על בסיס משתני זמן, מיקום וסוג הפנייה. יכולת חיזוי זו יכולה לסייע בתכנון כוח אדם ובניהול עומסים במוקד השירות.

מדדי הצלחה (KPI):
הצלחת הפרויקט נמדדה באמצעות מספר מדדים מרכזיים:

ברמה התפעולית:

- זיהוי שעות וימים עם עומס פניות גבוה לצורך תכנון כוח אדם.
- זיהוי רחובות או אזורים עם ריכוז פניות חריג לצורך תיעדוף טיפול תשתיתי.
- זיהוי סוגי פניות הגורמים לחלק משמעותי מזמן הטיפול הכולל.

ברמת החיזוי:

- פיתוח מודל חיזוי המסוגל להעריך את נפח הפניות העתידי בדיוק מספק.
- השגת ביצועי חיזוי טובים יותר ממודל בסיסי במדדים כגון MAE או . RMSE

סקירת ספרות

מסקירת הספרות בתחום חיזוי עומסים במוקדי שירות עולה כי למאפייני זמן תפקיד מרכזי בהסבר ובחיזוי נפח הפניות. בפרט, שעת היום והיום בשבוע נמצאו כמנבאים בסיסיים וחזקים של נפח השיחות.

בנוסף לדפוסים הקשורים לזמן, הספרות מצביעה על השפעתם של **גורמים חיצוניים** על נפח הפניות למוקדי שירות. בין גורמים אלו ניתן למנות חגים, פרסומים, אירועים ומצבי חירום. לדוגמה, תנאי מזג אוויר חריגים והפסקות חשמל זוהו כגורמים שעשויים להשפיע על היקף הפניות.

ממצא נוסף העולה מסקירת הספרות הוא קיומם של **דפוסים עונתיים**, ובפרט דפוסים שבועיים ויומיים החוזרים באופן עקבי במחקרים שונים, ללא קשר לתחום שבו פועל מוקד השירות.

לצורך חיזוי נפח הפניות נעשה בספרות שימוש במודלים שונים לחיזוי סדרות עתיות. בין המודלים הנפוצים שנמצאו בסקירה ניתן למנות את **ARIMA** ואת **LSTM**. מודלים אלו מאפשרים להתבסס על נתוני עבר לצורך זיהוי דפוסים וחיזוי נפח הפניות העתידי.

הידע הקיים והפער המחקרי

על בסיס סקירת הספרות ניתן להבחין בין תחומים שבהם קיים ידע מחקרי מבוסס לבין תחומים שבהם עדיין קיים פער. מבחינת **הידע הקיים**, קיים קונצנזוס רחב בספרות וכלים מוכחים לחיזוי עומסים על בסיס משתני זמן, ובפרט **שעה ביום ויום בשבוע**. כמו כן, קיימות מתודולוגיות חיזוי מבוססות ומוכחות המאפשרות לזהות דפוסים עתיים ולחזות את היקף הפניות. עם זאת, נמצא **פער מחקרי משמעותי** בכל הנוגע לרמת הפירוט של החיזוי. בפרט, כמעט ולא נמצא מחקר העוסק בחיזוי עומסים **לפי אזור גיאוגרפי בתוך העיר**. בנוסף, קיים פער בהבנת ההבדלים בדפוסי העומס בין **מחלקות שונות** .

תיאור הנתונים הגולמיים

מאגר הנתונים ששימש למחקר התקבל מהמועצה המקומית אבן יהודה וכלל כ־37,000 פניות ציבור שנאספו בין השנים 2022–2025. כל רשומה במאגר מייצגת פנייה בודדת שנפתחה במוקד השירות העירוני ומתעדת את המידע שנאסף לאורך מחזור החיים של הפנייה, החל ממועד פתיחתה ועד לסיום הטיפול בה.
הנתונים הגולמיים כללו מגוון רחב של משתנים תפעוליים, ובהם סוג המשימה, האגף והמחלקה המטפלים, מיקום הפנייה (רחוב), תיאור הפנייה, סטטוס הטיפול, תאריכי פתיחה, עדכון וסגירה, זמן הטיפול בפועל וזמן התקן (SLA). בנוסף, המאגר כלל פרטים מזהים של הפונה אשר הוסרו טרם תחילת העבודה, לצורך שמירה על פרטיות התושבים ועמידה בדרישות הגנת המידע.

מאגר נתונים זה שימש כבסיס לתהליך עיבוד הנתונים, ניקוי הנתונים ופיתוח מודלי החיזוי, אשר יוצגו בפרקים הבאים.

ניקוי ועיבוד נתונים

בשלב הראשון בוצע תהליך ניקוי נתונים שכלל:

- פירוק שדות זמן לתאריך ושעה ליצירת אחידות.

- הסרת נתונים רגישים ומזהים כגון שמות וכתובות מדויקות.

- תיקון שמות עמודות ואיחוד מבנה הנתונים בין הטבלאות.

- השלמת ערכים חסרים על בסיס קשרים בין משתנים (למשל בין סוג משימה לאגף).

- בדיקות איכות נתונים ובחינת התפלגויות לפני ואחרי הניקוי.

- הוספת פיצ'רים חדשים כגון נתוני מזג אוויר ועומס פניות לפי שעה.

לאחר מכן ביצענו קידוד ונרמול למשתנים הבאים:

- אגף – בעמודת "אגף" קיימות 12 קטגוריות שונות. לצורך עיבוד הנתונים השתמשנו בשיטת One-Hot Encoding, כלומר פיצלנו את המשתנה ל-12 עמודות בינאריות, כאשר בכל עמודה מופיע הערך 1 אם הפנייה שייכת לאותו אגף, ו-0 אחרת. בחרנו בשיטה זו מכיוון שאין סדר טבעי בין הקטגוריות, ולכן חשוב שכל אגף יקבל ייצוג נפרד ושווה לצורך הניתוחים והמודלים בהמשך.
- מחלקה – בעמודת "מחלקה" הופיעו בתחילה כמה עשרות קטגוריות שונות. לכן בשלב הראשון איחדנו קטגוריות דומות (לדוגמה "חזות-אשפה ביתית" עם "חזות-כללי"). לאחר האיחוד נותרו 15 קטגוריות, ועליהן ביצענו One-Hot Encoding, בדומה לעמודת "אגף". שיטה זו מאפשרת לשמור על המשמעות של כל מחלקה ולשלב אותה בצורה יעילה בניתוחים ובמודלים בהמשך.
- יום בשבוע – בעמודה המקורית צוינו ימי השבוע בצורה מילולית ("ראשון", "שני" וכו'). המרנו אותם לערכים מספריים (ראשון = 1, שני = 2 וכן הלאה). בחרנו בקידוד זה משום שלמשתנה קיימת משמעות סדרתית טבעית, שכן ימי השבוע מהווים רצף כרונולוגי. ייצוג מספרי זה מאפשר לשמור על הסדר ולבחון דפוסים בעומס הפניות לאורך השבוע.
- עונה – עונות השנה הופיעו בתחילה כערכים מילוליים ("חורף", "אביב", "קיץ", "סתיו"). המרנו אותן לערכים מספריים (חורף = 1, אביב = 2, קיץ = 3, סתיו = 4). קידוד זה נבחר משום שהמשתנה מייצג מחזוריות עונתית לאורך השנה, ולכן ייצוג מספרי זה מאפשר לנתח בצורה נוחה מגמות עונתיות בעומס הפניות למוקד.
- נפתחה בחג – עמודה זו היא עמודה בינארית. בעמודה המקורית הופיע הערך TRUE אם הפנייה נפתחה במהלך חג, ו-FALSE אם נפתחה ביום רגיל. בהתאם לכך המרנו את TRUE ל-1 ואת FALSE ל-0. קידוד בינארי מתאים למשתנים בעלי שתי אפשרויות בלבד ומאפשר לשלב את המשתנה בצורה ישירה בניתוחים סטטיסטיים ובמודלים חיזויים, תוך שמירה על משמעותו המקורית.

סטטיסטיקה תיאורית

לצורך הבנת מבנה הנתונים ואפיון דפוסי הפעילות, בוצעו מספר ניתוחים סטטיסטיים תיאוריים. ניתוחים אלו אפשרו לבחון את התפלגות הנתונים, לזהות מגמות וקשרים בין משתנים שונים, ולהפיק תובנות ראשוניות ששימשו בסיס להמשך המחקר.

קשר בין עומס ליום בשבוע-

לצורך בחינת ההבדלים ברמת העומס בין ימי השבוע בוצע **מבחן Kruskal–Wallis**, המתאים להשוואת מספר קבוצות כאשר לא ניתן להניח התפלגות נורמלית של הנתונים.

תוצאות המבחן:

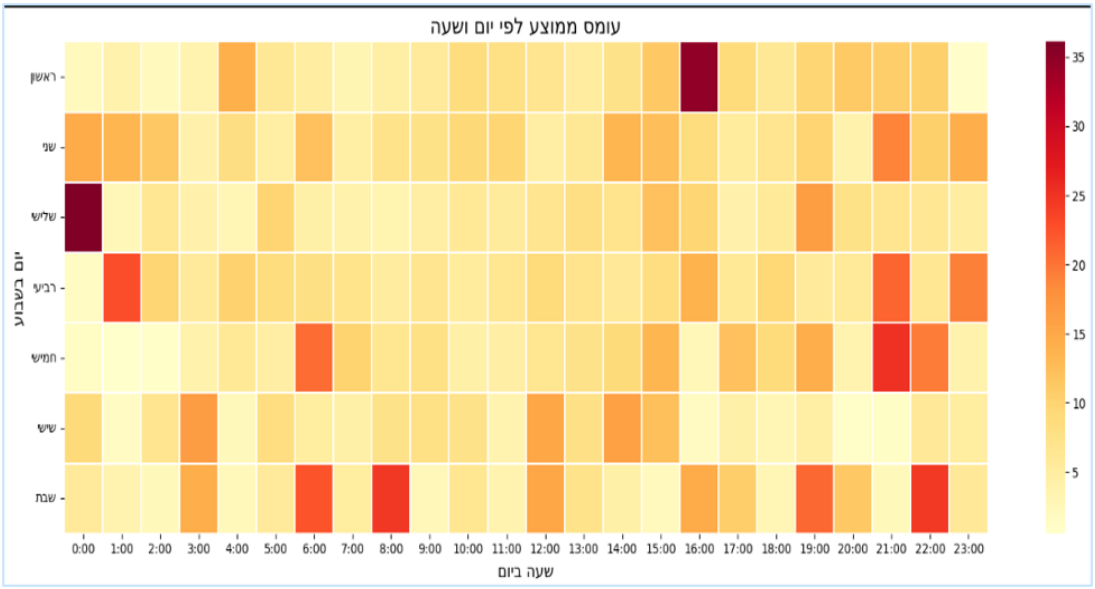
- מבחן: **Kruskal–Wallis**
- Statistic (H) = **230.67**
- p-value = **5.52×10^{-47}**

ממצאים:

- נמצא קשר מובהק סטטיסטית בין יום בשבוע לרמת העומס.
- רמת העומס אינה אחידה לאורך השבוע, וקיימות שעות פעילות שבהן העומס גבוה יותר.

תובנות:

- מומלץ לתגבר כוח אדם בימים ובשעות המאופיינים בעומסים גבוהים.
- תכנון משמרות בהתאם לדפוסי העומס עשוי לשפר את זמני המענה ולהפחית עומסים.



קשר בין סוג המשימה לזמן הטיפול-

לצורך בחינת ההבדלים בזמן הטיפול בין סוגי המשימות השונים בוצע **מבחן Kruskal–Wallis**, המתאים להשוואת מספר קבוצות בלתי תלויות כאשר לא ניתן להניח התפלגות נורמלית של הנתונים.

תוצאות המבחן:

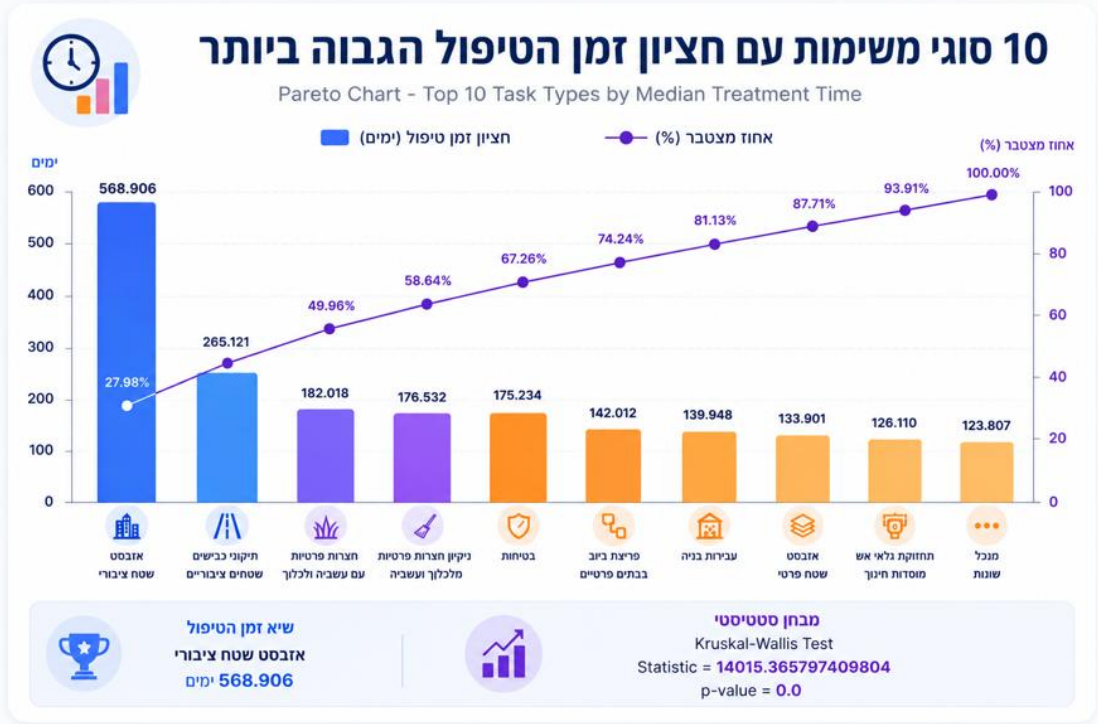
- מבחן: **Kruskal–Wallis**
- Statistic (H) = **14015.37**
- p-value < **0.001**

ממצאים:

- נמצא קשר מובהק סטטיסטית בין סוג המשימה לבין זמן הטיפול.
- משימות אזבסט בשטח ציבורי הציגו את חציון זמן הטיפול הגבוה ביותר, ואחריהן תיקוני כבישים ומשימות נוספות.

תובנות:

- מומלץ להקצות משאבים ותהליכי טיפול ייעודיים למשימות בעלות זמני טיפול ארוכים.
- זיהוי המשימות המעכבות מאפשר תעדוף נכון יותר של משימות וצמצום זמני טיפול.



קשר בין משתנים שונים לרמת העומס-

לצורך בחינת השפעתם של משתנים שונים על רמת העומס בוצעו **מבחני Kruskal–Wallis**, אשר נועדו לבחון האם קיימים הבדלים מובהקים ברמת העומס בין קבוצות שונות של כל משתנה. מבחן זה נבחר מאחר שאינו מניח התפלגות נורמלית של הנתונים ומתאים להשוואה בין מספר קבוצות בלתי תלויות.

תוצאות המבחנים:

מבחן	p-value
סוג משימה ↔ עומס	< 0.001
אגף ↔ עומס	< 0.001
חג ↔ עומס	< 0.001
עונה ↔ עומס	< 0.001

ממצאים:
נמצאו קשרים מובהקים סטטיסטית בין רמת העומס לבין סוג המשימה, האגף, חג ועונה.
תובנות:
עומס הפניות מושפע ממספר גורמים תפעוליים ולא ממשתנה יחיד.

גיבוש התכונות שיכללו ברשומת הקלט

לאחר ניקוי ועיבוד הנתונים גובשה רשומת הקלט ששימשה לאימון ולהערכת מודלי למידת המכונה. רשומת הקלט כללה תכונות מקוריות מתוך הנתונים וכן תכונות חדשות שנוצרו בתהליך הנדסת פיצ'רים. בחירת התכונות נעשתה בהתאם לרלוונטיות שלהן לחיזוי נפח הפניות ולחיזוי חריגה מזמן התקן (SLA).

התכונות חולקו לקבוצות הבאות:

מאפייני הפנייה
מאפיינים אלו נלקחו ישירות מרשומת הפנייה וכללו:

- סוג המשימה.
- האגף המטפל.
- המחלקה המטפלת.
- הרחוב שבו נפתחה הפנייה.

מאפייני זמן ועונתיות
מתאריך ושעת פתיחת הפנייה נגזרו מספר תכונות המתארות את מאפייני הזמן והעונתיות של הפנייה:

- יום בשבוע.
- חודש.
- עונת השנה.
- שעה ביום.
- חלק היום.
- האם הפנייה נפתחה ביום שלפני חג.
- האם הפנייה נפתחה ביום שלאחר חג.
- האם הפנייה נפתחה בתקופת שעון קיץ.
- האם הפנייה נפתחה בשעות חושך.
- האם מועד הפנייה חל בתקופת חופשה.

נתוני החגים והחופשות הותאמו ללוח השנה הרשמי.

מאפייני עומס
כדי לייצג את רמת העומס במערכת בזמן פתיחת הפנייה נוצרו מאפיינים המבוססים על מספר הפניות שנפתחו בסביבת הזמן וההקשר של הפנייה. בין היתר חושבו:

- מספר הפניות שנפתחו באותו יום.
- מספר הפניות שנפתחו באותה שעה.
- מספר הפניות שנפתחו באותו חלק של היום.
- מספר הפניות המצטברות באותו אגף באותו יום.
- מספר הפניות מאותו סוג משימה באותו יום.

- יחס עומס סוג המשימה באותו יום.

מאפיינים אלו מאפשרים לייצג הן את העומס הכללי במערכת והן את העומס הספציפי הקשור לאגף ולסוג המשימה של הפנייה.

מאפיינים גאוגרפיים והיסטוריים
נוצרו מאפיינים המבוססים על היסטוריית הפניות ברחוב שבו נפתחה הפנייה. לצורך כך חושבו:

- `street_past_calls_30d` – מספר הפניות שנפתחו באותו רחוב במהלך 30 הימים שקדמו לפתיחת הפנייה.
- `street_prev_avg_load` – ממוצע עומס הפניות ההיסטורי באותו רחוב.
- `street_time_since_prev` – הזמן שחלף מאז הפנייה הקודמת שנפתחה באותו רחוב.

כך שולב ברשומת הקלט מידע היסטורי על רמת הפעילות ברחוב ולא רק מידע על הפנייה הנוכחית.

מאפייני מורכבות ולחץ
נוצרו מאפיינים המתארים את מורכבות הפנייה ואת רמת הלחץ התפעולי בזמן פתיחתה:

- אורך תיאור הפנייה.
- צפיפות משימות דומות שנפתחו באותו יום.
- ממוצע משוקלל של עומס הפניות לפי סוג המשימה.

בסך הכול כללה רשומת הקלט למעלה מ־40 תכונות, המשלבות תכונות מקוריות ותכונות שנגזרו באמצעות הנדסת פיצ'רים. התכונות כללו מידע על מאפייני הפנייה, זמן ועונתיות, עומס, מיקום והיסטוריית פעילות, וכן מורכבות ולחץ תפעולי.

השלבים בתהליך למידת המכונה

לאחר השלמת שלבי ניקוי הנתונים, הנדסת הפיצ'רים וגיבוש רשומת הקלט, החל תהליך בחינה, אימון והערכת מודלי למידת מכונה. מטרת התהליך הייתה לזהות את המודלים המתאימים ביותר למשימות החיזוי שהוגדרו: חיזוי חריגות מזמן התקן (SLA) וכן חיזוי נפח הפניות העתידי למוקד השירות. במסגרת התהליך נבחנו מודלים שונים, הוערכו ביצועיהם באמצעות מדדי הערכה מתאימים, ונבחרו המודלים שסיפקו את יכולת החיזוי הטובה ביותר עבור כל משימה.

בשלב הראשון הוגדר **משתנה המטרה** עבור מודל הסיווג, כאשר כל פנייה סווגה בהתאם לשאלה האם הטיפול בה חרג מזמן התקן (חרגה-1, לא חרגה-0)

בשלב הבא נבחנו מספר אלגוריתמים מבוססי עצים, ובהם Random Forest, XGBoost ו־CatBoost. כל אחד מהמודלים אומן על אותם נתונים, וביצועיו הוערכו באמצעות מדדי Accuracy, Precision, Recall, F1 Score ו־ROC AUC, במטרה להשוות בין יכולות החיזוי שלהם ולבחור את המודל המתאים ביותר למשימה.

לאחר השוואת ביצועי המודלים נמצא כי CatBoost הציג את הביצועים הגבוהים והיציבים ביותר בכלל האגפים, ולכן נבחר כמודל הסופי לחיזוי חריגות מזמן התקן.

לאחר בחירת המודל בוצע ניתוח באמצעות SHAP (SHapley Additive exPlanations), שמטרתו להסביר את החלטות המודל ולזהות את המשתנים המשפיעים ביותר על תחזיותיו. ניתוח זה אפשר להבין אילו מאפיינים תרמו באופן המשמעותי ביותר לסיכוי שפנייה תחרוג מזמן התקן, ובהם סוג המשימה, חודש פתיחת הפנייה וסוג האגף.

בנוסף למודל הסיווג, נבחן מודלים לחיזוי נפח הפניות באמצעות סדרות זמן. לצורך כך בוצעה אגרגציה של כלל הפניות לרמה יומית, כאשר עבור כל יום חושב מספר הפניות הכולל, מספר הפניות בכל אגף ונוספו מאפייני זמן כגון יום בשבוע, חודש, שנה ומספר השבוע בשנה. נוצרו משתני Lag, המתארים את מספר הפניות בימים קודמים, במטרה לאפשר למודל ללמוד את הדפוסים ההיסטוריים של סדרת הזמן. בחנו את ביצועי המודל ע"י שינוי משתני הלגים.

המודלים שהשתמשנו בהם לחיזוי סדרות הזמן הם LSTM ו־SARIMA, והשוואת ביצועיהם התבססה על מדד MAE. תוצאות ההשוואה הראו כי מודל LSTM השיג את ביצועי החיזוי הטובים ביותר, בעוד ששילוב משתנים חיצוניים, כגון מזג אוויר וחגים, לא שיפר את דיוק התחזיות.

ניתוח הגרפים

מפת חום: עומס ממוצע לפי יום ושעה

המפה מציגה את העומס הממוצע לכל שילוב של יום בשבוע ושעה. שני התאים הקיצוניים ביותר הם יום שלישי בשעה 00:00, מעל 30, ויום ראשון בשעה 16:00. שניהם נמצאים בשעות עם נפח פניות נמוך, ולכן רשומה בודדת עם יחס עומס קיצוני מספיקה כדי לגרור את הממוצע של אותו תא כלפי מעלה. המסקנה היא שבמשתנה מוטה כמו עומס (יחס) עדיף להשתמש בחציון או להציג לצד הממוצע גם את גודל המדגם.

מטריצת קורלציות ותרשים 20 המתאמים המובילים

מטריצת הספירמן בין כל הפיצ'רים המספריים שימשה לזיהוי זוגות עמודות עם קורלציה גבוהה מ-0.8, וביניהם נמצאו כמה זוגות עם קורלציה מושלמת- 1.0, כמו מחלקה_Unknown מול אגף_Unknown, ואגף_כספים מול מחלקה_אוספי פיננסי. זו בדיקת תקינות שימושית שחושפת עמודות כפולות מבחינה מבנית. תרשים 20 המתאמים המובילים מול העומס מראה שהמתאמים החזקים ביותר הם זמן טיפול בפועל, 0.886, וזמן טיפול בימים, 0.871, שני משתנים שהם בעצם מרכיבים ישירים של עומס (יחס) עצמו, ולכן לא באמת פיצ'רים חיצוניים אלא חלק מהגדרת המטרה. ניתן להוציא את שני המשתנים האלה מסט הפיצ'רים.

מגמת שנים: פניות וחריגות 2022 עד 2025

תרשים העמודות המוערמות לפי שנה מראה שכמות הפניות וכמות החריגות כמעט הכפילו את עצמן על פני ארבע שנים, מ-2,272 חריגות ב-2022 ל-5,040 ב-2025, כאשר שיעור החריגה היחסי נשאר יציב סביב 30 עד 35 אחוז לאורך כל התקופה.

פארטו: חציון זמן טיפול לפי סוג משימה

עשרת סוגי המשימות עם חציון זמן הטיפול הגבוה ביותר נעים בין 124 ל-569 ימים, כשבראש הרשימה אזבסט בשטח ציבורי, 568.9 ימים, ותיקוני כבישים ציבוריים, 270.6 ימים. אלה תהליכים ארוכים במהותם, פינוי אסבסט למשל דורש קבלן מורשה ואישור המשרד להגנת הסביבה, ולא מדובר בכשל תפעולי אלא בזמן טיפול תקין להליך רגולטורי.

שיעור חריגה לפי שעת פתיחה, אגפים קטנים

התרשים מראה שיעור חריגה נמוך בשעות הלילה, סביב 0.20 עד 0.40, עלייה חדה לשיא של כ-0.70 בשעה 6 בבוקר, ורמה גבוהה יציבה של 0.6 עד 0.67 עד השעה 12, ואז ירידה הדרגתית ל-0.45 עד 0.56 אחר הצהריים והערב. מדובר בדפוס עקבי וברור, אבל שווה לאחר חקירה המסקנה שהוא נבדק כמדד גולמי בלי בקרה על סוג המשימה, ומאחר שסוג המשימה הוא המשתנה החזק ביותר בדאטה, חלק מהדפוס הזה עשוי לשקף אילו סוגי משימות נפתחים בכל שעה ולא רק את השעה עצמה.

ניתוח המודלים

נבנו חמישה מודלים: ארבעה מסווגים בינאריים מבוססי CatBoost, אחד לכל אגף או קבוצת אגפים, רשת נוירונים גלובלית עם Embedding לסוג משימה, ומודל LSTM לחיזוי נפח פניות יומי. בכל ארבעת מודלי ה-CatBoost הוגדר היעד באותו אופן, חריגה כאשר עומס (יחס) גדול מ-1, ונעשה שימוש בפיצ'רים שנגזרו רק מרגע פתיחת הפנייה, לא מנתוני הסגירה או הטיפול, כדי לשמור על תרחיש חיזוי ריאלי.

פיצ'ר מוביל	AUC	% חריגה	N	מודל
סוג משימה (18%)	0.839	30.7%	4,130	מ.מ. אבן יהודה
סוג משימה (29%)	0.832	31.7%	23,992	אגף תפעול
סוג משימה (29%)	0.759	30.1%	5,660	אגף ביטחון
סוג משימה (17%)	0.841	59.9%	3,240	אגפים קטנים מאוחדים
	0.791	~34%	37,022	רשת נוירונים

מודל אגף התפעול הוא הגדול ביותר, כ-24 אלף שורות, ומגיע ל-AUC של 0.832. מודל האגפים הקטנים, שמאחד תשעה אגפים שונים כמו הנדסה, חינוך וכספים תחת קטגוריה אחת, מגיע ל-AUC הגבוה ביותר מבין המודלים, 0.841, למרות הטרוגניות גדולה יותר בדאטה שלו. מודל אגף הביטחון הוא החלש ביותר, 0.759, מה שמעיד על כך שהגורמים שמסבירים חריגה שם שונים מהדפוס שחוזר בשאר האגפים. ברשת הנוירונים הגלובלית, שכוללת Embedding ייעודי לסוג המשימה ומאומנת על כל הדאטה יחד, ה-AUC נמוך יותר, 0.791, אבל היא בנויה מרשימת החרגת פיצ'רים מפורשת וזהירה שמונעת דליפת מידע מנתוני הסגירה והטיפול.

מודל ה-LSTM שונה במהותו: הוא לא מסווג פנייה בודדת אלא חוזה את נפח הפניות היומי הכולל, על סמך חלון של 14 יום אחורה, וחלוקת train/test כרונולוגית ולא אקראית, כפי שמתאים למשימת חיזוי סדרה עתית. הוא השיג MAE של 12.05 ו-RMSE של 14.72, לעומת בייסליין נאיבי שמבוסס על תחזית ממוצע עם MAE של 17.9, שיפור של 32.7 אחוז. בנוסף נבנה מודל רשת נוירונים נוסף שמצטבר לרמת יום ומשמרת, בוקר צהריים ולילה, שאומן על הדאטה אך טרם נבדק סופית מול סט מבחן.

ניתוח הבדיקות שאחרי הרצת המודלים

חשיבות פיצ'רים

בכל אחד מארבעת מודלי ה-CatBoost, ללא יוצא מהכלל, סוג המשימה המנוקה הוא הפיצ'ר בעל החשיבות הגבוהה ביותר, בין 17 ל-29 אחוז, לפני כל משתנה אחר. אחריו מופיעים בעקביות חודש ושנת פתיחה, טמפרטורה, ופיצ'רי עומס שנבנו במיוחד לפרויקט כמו יחס עומס סוג משימה ביום ופניות ברחוב ב-30 הימים האחרונים. העקביות הזו על פני ארבעה מודלים שונים, שכל אחד אומן על תת אוכלוסייה אחרת, מחזקת את המהימנות של הממצא.

SHAP

הופעל SHAP TreeExplainer על מודל אגף התפעול ועל מודל האגפים הקטנים, עם תרשים summary plot שמראה גם את כיוון ההשפעה של כל פיצ'ר על ההסתברות לחריגה, לא רק את גודלה. זה מוסיף שכבת פרשנות מעבר לחשיבות הפיצ'רים הרגילה ומאפשר להסביר לבעל עניין לא טכני למה מודל חוזה חריגה גבוהה למקרה ספציפי.

כיול סף ההחלטה

עבור המודלים של מ.מ. אבן יהודה והאגפים הקטנים, נבדקו שישה ספי החלטה שונים, בין 0.35 ל-0.60, עם טבלת precision ו-recall מלאה לכל סף. זה מראה הבנה של הפשרה העסקית: סף נמוך יותר תופס יותר חריגות אמיתיות אבל מייצר יותר התרעות שווא, וסף גבוה יותר עושה את ההפך. הבחירה הסופית, למשל 0.45 עבור מ.מ. אבן יהודה, נעשתה מתוך השוואה מפורשת ולא כברירת מחדל אוטומטית של 0.5.

מטריצות בלבול ופילוחים נוספים

לכל מודל הוצגה מטריצת בלבול על סט המבחן. מעבר לכך נעשו פילוחים נוספים של שיעור חריגה: לפי סוג משימה, שבו נמצא שכ-15 סוגים אחראים לכ-66 אחוז מהחריגות באגף תפעול, לפי רחוב, לפי חודש, ולפי קיבוץ לחמישוני כמות פניות היסטורית ברחוב, אורך תיאור הפנייה, עומס היסטורי ברחוב וטמפרטורה. הפילוחים האלה חורגים מהערכת דיוק המודל הרגילה ומתפקדים כניתוח תיאורי משלים שמסביר את הסיפור שמאחורי התחזיות.

מסקנות ותובנות

הבחירה לבנות מודל נפרד לכל אגף, ולא מודל אחד גלובלי, מתגלה כהחלטה נכונה: מודל אגף הביטחון חלש יותר לא בגלל תקלה אלא כי האגף הזה שונה מבנית, וזו בדיוק התובנה שמודל אחד משותף היה מטשטש.

הממצא העסקי החזק ביותר בעבודה הוא ריכוז החריגות בקבוצה קטנה של סוגי משימות: כ-15 קטגוריות מתוך כ-176 אחראיות לכ-66 אחוז מהחריגות, ובכל מודל שנבנה סוג המשימה מוביל את חשיבות הפיצ'רים בפער גדול. זו לא רק תוצאה סטטיסטית אלא כלי תעדוף ישיר להנהלה. לצידו, ההבחנה בין תהליכים רגולטוריים ארוכים במהותם כמו אסבסט לבין חריגות שמעידות על זמן תקן לא ריאלי כמו הדברת יתושים מוסיפה עומק: לא כל חריגה מספרת אותו סיפור.

מודל ה-LSTM, עם שיפור של 32.7 אחוז על פני בייסליין וחלוקה כרונולוגית נכונה למשימת סדרה עתית, מתאים לשימוש מעשי בתכנון כוח אדם יום קדימה, ומהווה את התוצר הבשל ביותר בעבודה מבחינת מוכנות לשימוש.

שאלות ותשובות

שאלה: האם איכות הנתונים לאחר הניקוי מספיקה כדי להבטיח שהתוצאות תקפות?

תשובה: מפת החום הראשונה חושפת שני תאים קיצוניים, יום שלישי בשעה 00:00 ויום ראשון בשעה 16:00, בשעות עם מעט מאוד פניות. בתאים עם מעט נתונים, רשומה בודדת עם יחס עומס קיצוני, עד כמעט 1000 במקרה הגרוע, גוררת את הממוצע כלפי מעלה. הפתרון המתבקש הוא להציג חציון במקום ממוצע ולצרף גודל מדגם לכל תא בגרפים מהסוג הזה.

שאלה: מדוע משתנה המטרה הומר לבינארי?

תשובה: משתנה עומס (יחס) מחושב כחלוקה של זמן טיפול בפועל בזמן תקן, ולכן לא יציב כשזמן התקן קטן: איחור קצר במשימה עם זמן תקן קצר מייצר יחס גדול מאוד. זו הסיבה לפיזור הקיצוני שלו, מקסימום כמעט 1000 מול חציון של 0.39. ההמרה לבינארי היא כלי מתאים להתמודד עם חוסר היציבות הזה, לא ויתור על יכולת המודל להתמודד עם שונות.

שאלה: האם נבדקה דליפת מידע בין אימון למבחן?

תשובה: זו נקודה שנבדקה ישירות מול הקוד. יש הבדל בין שתי קבוצות פיצ'רים.

פיצ'רים שנבדקו ונמצאו תקינים: הפיצ'ר "פניות מצטברות אגף ביום" חושב לאחר מיון הפניות לפי תאריך ושעת הפתיחה, ולאחר מכן באמצעות `cumcount()` (ספירת הפניות הקודמות בתוך כל קבוצה) עבור כל אגף בכל יום. באופן זה, עבור כל פנייה נספרות רק הפניות שנפתחו לפניה באותו אגף ובאותו יום, ולכן הפיצ'ר מבוסס על מידע שהיה זמין עד למועד פתיחת הפנייה ואינו כולל מידע עתידי.

באופן דומה חושב הפיצ'ר "זמן מאז פנייה קודמת ברחוב". הפניות מוינו לפי רחוב ומועד הפתיחה, ולאחר מכן חושב באמצעות `diff()` הזמן שחלף מאז הפנייה הקודמת באותו רחוב. גם פיצ'ר זה מסתמך רק על פנייה קודמת ולכן אינו משתמש במידע עתידי.

שני הפיצ'רים נבדקו ונמצאו תקינים מבחינת **מניעת דליפת מידע** , שכן חישובם מתבצע באופן כרונולוגי ועל בסיס מידע שהיה קיים עד לרגע פתיחת הפנייה בלבד.

פיצ'ר שנמצאה בו בעיה אמיתית: במסגרת בדיקת תקינות הפיצ'רים התגלתה בעיה בפיצ'ר "יחס עומס סוג משימה ביום". בחישוב הפיצ'ר נמצאו שתי נקודות העלולות לגרום לדליפת מידע. ראשית, ממוצע העומס עבור כל סוג משימה חושב על פני כל תקופת הנתונים, ולכן עבור פנייה משנת 2022 הממוצע כלל גם נתונים משנים מאוחרות יותר. שנית, מספר הפניות היומי חושב עבור כל הפניות שנפתחו באותו יום, ולא רק עבור הפניות שנפתחו לפני הפנייה הנוכחית. כך, למשל, פנייה שנפתחה בשעה 08:00 קיבלה ספירה שכללה גם פניות שנפתחו בשעה 23:00 באותו יום.

אותה בעיה נמצאה גם בפיצ'רים "פניות סוג משימה באותו יום", "פניות באותה שעה" ו־"פניות בחלק יום", שבהם הספירה בוצעה על כלל הקבוצה ולא רק על הרשומות שקדמו לפנייה. לבעיה זו הייתה השפעה בפועל על שלושת המודלים המרכזיים – מ.מ. אבן יהודה, תפעול וביטחון – שבהם נעשה שימוש בפיצ'ר "יחס עומס סוג משימה ביום", ולכן היא עשויה להשפיע על ערכי ה־AUC שהתקבלו.

בנוסף, נבדקו הפיצ'רים "ממוצע עומס היסטורי ברחוב", "פניות ברחוב ב־30 ימים אחרונים" ו־"משקל_עומס_רחוב". פיצ'רים אלו הגיעו מוכנים בקובץ הנתונים שנטען בתחילת המחברת ולא חושבו בקוד הזמין לבדיקה. לכן, לא ניתן היה לאמת באופן חד־משמעי כי הם חושבו על בסיס מידע היסטורי בלבד.

כדי למנוע דליפת מידע, הוגדר אופן חישוב מתוקן: הממוצעים ההיסטוריים יחושבו באמצעות חלון נגלל (Rolling Window) המתייחס רק לימים שקדמו למועד הפנייה, ואילו ספירת הפניות באותו יום, באותה שעה ובאותו חלק יום תבוצע לאחר מיון כרונולוגי באמצעות `cumcount()` (ספירת הפניות הקודמות בתוך כל קבוצה). כך כל פיצ'ר יתבסס רק על מידע שהיה זמין עד למועד פתיחת הפנייה.

שאלה: האם מודל ה-LSTM הוערך כראוי?

תשובה: המודל דיווח MAE של 12.05 ו-RMSE של 14.72, לעומת בייסליין נאיבי עם MAE של 17.9 ו-RMSE של 22.2, שיפור של 32.7 אחוז. חסרה השוואה מפורשת בין ה-RMSE לסטיית התקן של משתנה המטרה, וכן דיווח R^2 וניתוח שאריות. נפח הפניות היומי בתקופת הבדיקה נאמד בכ-35 עד 40 ליום, כך ששגיאה של כ-12 מהווה טעות יחסית של כ-30 עד 35 אחוז, נתון ששווה לחשב ולדווח במפורש.

שאלה: הרחובות שנמצאו רלוונטיים בניתוח: האם מדובר ברחובות מרכזיים, ומה מאפיין אותם?

תשובה: מודלי ה-CatBoost לא כללו את עמודת רחוב כמשתנה קטגוריאלי גולמי, אלא פיצ'רים מצטברים ברמת הרחוב כמו ממוצע עומס היסטורי ברחוב ומשקל עומס רחוב. הרחובות בפועל עם הכי הרבה חריגות, לפי הניתוח התיאורי של אגף תפעול:

רחוב	כמות פניות	כמות חריגות	שיעור חריגה
המייסדים	1,231	514	41.8%
העצמאות	1,232	374	30.4%
ההדרים	1,142	340	29.8%
השרון	887	229	25.8%
המחתרת	705	224	31.8%

בדאטה כבר קיימות שתי עמודות שעונות על השאלה בלי מקור חיצוני, האם_ציר_ראשי ואיזור_צירים ראשיים, ופשוט לא הוצלבו מול הרשימה הזו. הוספת מפת הישוב בפועל דורשת שכבת GIS, קואורדינטות רחוב או קובץ צורות של הרשות, שלא הייתה זמינה במחברת הנוכחית.